


# Análisis Exploratorio de Datos

# Datos: Expectativas y Realidad




# Datos: Expectativas y Realidad

En general, se tiende a pensar que los datos siempre están disponibles de forma perfecta, pero la realidad indica que esto no es así...

|   | PID         | ST_NUM | ST_NAME    | OWN_OCCUPIED | NUM_BEDROOMS | NUM_BATH | SQ_FT  |
|---|-------------|--------|------------|--------------|--------------|----------|--------|
| 0 | 100001000.0 | 104.0  | PUTNAM     | Y            | 3.0          | 1        | 1000.0 |
| 1 | 100002000.0 | 197.0  | LEXINGTON  | N            | 3.0          | 1.5      | NaN    |
| 2 | 100003000.0 | NaN    | LEXINGTON  | N            | NaN          | 1        | 850.0  |
| 3 | 100004000.0 | 201.0  | BERKELEY   | 12           | 1.0          | NaN      | 700.0  |
| 4 | NaN         | 203.0  | BERKELEY   | Y            | 3.0          | 2        | 1600.0 |
| 5 | 100006000.0 | 207.0  | BERKELEY   | Y            | NaN          | 1        | 800.0  |
| 6 | 100007000.0 | NaN    | WASHINGTON | NaN          | 2.0          | HURLEY   | 950.0  |
| 7 | 100008000.0 | 213.0  | TREMONT    | Y            | NaN          | 1        | NaN    |
| 8 | 100009000.0 | 215.0  | TREMONT    | Y            | NaN          | 2        | 1800.0 |

# Análisis Exploratorio de Datos



# Análisis Exploratorio de Datos

- En palabras simples, es una aproximación en el análisis de sets de datos para sumarizar sus características, a menudo valiéndose de métodos visuales.
- Utilizado también en etapas de preparación de datos en labores principalmente de reconocimiento y limpieza
- Utilizado para chequear hipótesis de trabajo en las etapas de modelamiento

# Análisis Exploratorio de Datos

*“Procedimientos para el análisis de datos, técnicas para la interpretación de los resultados de dichos procedimientos, vías para planear la recolección de datos que hagan el análisis más fácil, más preciso y exacto, y toda la batería de herramientas estadísticas que nos permitan analizar los datos”*

John Turkey - 1961 – The future of data analysis

# Análisis Exploratorio de Datos


## EDA – Exploratory Data Analysis

### IDA – Initial Data Analysis

- Manejar valores perdidos y data errónea
  - Detectar anomalías y outliers en los datos
  - Identificar las variables más importantes
  - Mapear la estructura de los datos
  - Chequear la completitud
  - Asegurar que los datos son apropiados para el caso de uso
- Sugerir hipótesis acerca de la causa de un fenómeno observado
  - Realizar/checkear supuestos para una posterior inferencia estadística
  - Apoyar la selección de herramientas y técnicas estadísticas
  - Proveer la base para futuros procesos de recolección de datos



# Técnicas y Herramientas





# Técnicas y Herramientas



## **1. Analizar una muestra**

- Entendimiento de los datos
- Técnicas de muestreo aleatorio
- Chequeo de estructura y tipos de dato
- Chequeo de valores nulos
- Chequeo de inconsistencias en los datos
- Chequeo de si la información se encuentra estandarizada o no
- Determinar necesidades de procesamiento
- Determinar necesidades de enriquecimiento
- Determinar la calidad de los datos

# Técnicas y Herramientas

## 2. Analizar una columna



- Ver información estadística resumida tal como media, mediana, stdev
- Analizar valores máximos y mínimos
- Graficar histogramas para ver la distribución de valores
- Graficar diagramas de caja en cada columna para identificar outliers
- Graficar diagramas de distribución para entender los datos cualitativamente
- Chequear el número de filas y columnas contra las expectativas



# Técnicas y Herramientas

## 3. Analizar la relación entre columnas

- Análisis de la correlación entre las variables
- Análisis visual distinguiendo valores categóricos
- Análisis visual (scatterplots, mapas de calor, etc)



# Técnicas y Herramientas

## 4. Procesamiento y Transformación


- Creación de nuevas variables y columnas
- Unión y concatenación de set de datos
- Agrupamiento de datos
- Pivoteo de tablas
- Binarización y codificación de datos
- Normalización/Desnormalización de datos (1F, 2F, 3F)
- Normalización / Estandarización (estadística) de los datos

|          |         | clicks |      |      |    |        |          | users |    |    |      |          |  |
|----------|---------|--------|------|------|----|--------|----------|-------|----|----|------|----------|--|
|          |         | year   | 2010 |      |    |        | SubTotal | 2010  |    |    |      | SubTotal |  |
|          |         | month  | 1    | 2    | 3  | 4      |          | 1     | 2  | 3  | 4    |          |  |
| host     | country |        |      |      |    |        |          |       |    |    |      |          |  |
| 1        | es      | 113    | 234  | 421  | 22 | 790.0  | 4        | 5     | 2  | 3  | 14.0 |          |  |
|          | fr      | 123    | 134  | 341  |    | 598.0  | 4        | 5     | 2  |    | 11.0 |          |  |
| SubTotal |         | 236    | 368  | 762  | 22 | 1388.0 | 8        | 10    | 4  | 3  | 25.0 |          |  |
| 2        | es      | 111    | 2    |      |    | 113.0  | 2        | 4     |    |    | 6.0  |          |  |
| SubTotal |         | 111    | 2    |      |    | 113.0  | 2        | 4     |    |    | 6.0  |          |  |
| 3        | es      |        |      | 34   | 1  | 35.0   |          |       | 2  | 1  | 3.0  |          |  |
| SubTotal |         |        |      | 34   | 1  | 35.0   |          |       | 2  | 1  | 3.0  |          |  |
| Max      |         | 236    | 368  | 762  | 22 | 1388.0 | 8        | 10    | 4  | 3  | 25.0 |          |  |
| Min      |         | 111    | 2    | 34   | 1  | 35.0   | 2        | 4     | 2  | 1  | 3.0  |          |  |
| Total    |         | 1041   | 1110 | 2388 | 69 | 4495.0 | 30       | 42    | 18 | 12 | 96.0 |          |  |

# Técnicas y Herramientas

## 5. Reducción de Datos

- Reducción de dimensionalidad
- Análisis de clusterización



# Tipos de estadística

Estadística univariada (estudia una sola variable), bivariada (estudia la relación entre dos variables), y multivariada (estudia tres o más variables).

**Descriptiva**

**Describir la muestra**

**Estadística**

**Inferencial**

La diferencia radica en que la estadística descriptiva procede a resumir y organizar esos datos para facilitar su análisis e interpretación, y la estadística inferencial procede a formular estimaciones y probar hipótesis acerca de la población a partir de esos datos resumidos y obtenidos de la muestra.

**Infiere conclusiones a partir de los datos que describen la muestra**

# Análisis Univariado



# Análisis Univariado

Es la forma más simple de análisis, en donde se analiza solamente una variable. El propósito principal de un análisis univariado es describir los datos, valiéndose de la estadística descriptiva, para encontrar patrones y develar fenómenos subyacentes difíciles de encontrar solamente observando los datos de forma aislada.

```
1 import pandas as pd
```

```
1 df = pd.read_csv('Salaries.csv')
```

```
1 df.head(2)
```

|   | Id | EmployeeName   | JobTitle                                       | BasePay   | OvertimePay | OtherPay  | Benefits | TotalPay  | TotalPayBenefits | Year | Notes | Agency        | Status |
|---|----|----------------|------------------------------------------------|-----------|-------------|-----------|----------|-----------|------------------|------|-------|---------------|--------|
| 0 | 1  | NATHANIEL FORD | GENERAL MANAGER-METROPOLITAN TRANSIT AUTHORITY | 167411.18 | 0.00        | 400184.25 | NaN      | 567595.43 | 567595.43        | 2011 | NaN   | San Francisco | NaN    |
| 1 | 2  | GARY JIMENEZ   | CAPTAIN III (POLICE DEPARTMENT)                | 155966.02 | 245131.88   | 137811.38 | NaN      | 538909.28 | 538909.28        | 2011 | NaN   | San Francisco | NaN    |

Hagamos un análisis del dataset de Sueldos de San Francisco, en particular, de la columna sueldo base (BasePay) para ver cómo se comporta.

# Medidas de Tendencia Central

Son medidas estadísticas que pretenden resumir en un solo valor a un conjunto de valores, representando el centro en torno al cual se sitúan los datos.

- **Media:** corresponde al promedio aritmético, es decir, la suma de los valores dividido por la cantidad de valores.
- **Mediana:** corresponde al valor de la variable que ocupa la posición central en el conjunto de valores, es decir, el 50% de las observaciones tiene un valor igual o inferior a la mediana y el otro 50% un valor igual o superior a la mediana
- **Moda:** corresponde al valor que más se repite en un conjunto de datos.

# Medidas de Tendencia Central

Ahora veamos qué pasa con la variable sueldo base.

```
1 # media
2 df['BasePay'].mean()
```

```
66325.44884050643
```

El promedio de sueldo es de aproximadamente U\$ 66.325

```
1 # mediana
2 df['BasePay'].median()
```

```
65007.45
```

La mitad de las personas tiene un sueldo igual o inferior a U\$ 65.007

```
1 # moda
2 df['BasePay'].mode()
```

```
0    0.0
dtype: float64
```

El valor que más se repite es U\$0.0  
**Hemos descubierto un insight!!!**

# Medidas de Dispersión

Entregan información sobre la variación de la variable, en donde se busca resumir en un sólo valor la dispersión que tiene un conjunto de datos.

- **Rango de variación:** es la diferencia entre el mayor valor de la variable y el menor valor.
- **Varianza:** es la suma de las diferencias entre el valor y el promedio, al cuadrado, dividido por la cantidad de valores (\*)

$$Var(x) = \frac{\sum_1^n (x_i - \bar{X})^2}{n}$$

- **Desviación Estándar:** corresponde a la raíz cuadrada de la varianza, para que la medida de dispersión quede en la misma unidad que los valores de la variable.

$$\sigma^2 = Var(x)$$

# Medidas de Dispersión

Cuando se quiere estimar la desviación estándar como indicador estadístico de una población a partir de una muestra, es importante distinguir los conceptos de **población** y **muestra**.

En general, las muestras subestiman la variabilidad de la población. Esto se puede mejorar con la corrección de Bessel:

- Si estamos estimando la desviación estándar (o la varianza) de la población a partir de una muestra, debemos dividir por  $n - 1$
- Si estamos midiendo la desviación estándar (o la varianza) de la población, debemos dividir por  $n$ .

\*Corrección de Bessel

[https://es.wikipedia.org/wiki/Correcci%C3%B3n\\_de\\_Bessel](https://es.wikipedia.org/wiki/Correcci%C3%B3n_de_Bessel)

# Medidas de Dispersión

A continuación, algunos ejemplos.

```
1 # rango de variación
2 rv = df['BasePay'].max() - df['BasePay'].min()
3 print(rv)
```

319441.02

```
1 # varianza, por defecto utiliza n - 1 (estimación de la población a partir de una muestra)
2 df['BasePay'].var()
```

1828814049.0424156

```
1 # varianza utilizando n (medición de la desviación de la población)
2 df['BasePay'].var(ddof=0)
```

1828801695.9467416

```
1 # desviación estándar, por defecto utiliza n - 1
2 df['BasePay'].std()
```

42764.63549525958

```
1 # desviación estándar, utilizando n
2 df['BasePay'].std(ddof=0)
```

42764.49106381066

# Medidas de Posición

Las medidas de posición son indicadores estadísticos que permiten resumir los datos en uno sólo, o dividir su distribución en intervalos del mismo tamaño. Las medidas más habituales son las siguientes:


- **El cuartil:** divide la distribución en 4 partes iguales. De esta forma, existen tres cuartiles, Q1, Q2 y Q3.
- **El quintil:** divide la distribución en 5 partes, por lo tanto hay 4 quintiles.
- **El decil:** divide la distribución en 10 partes iguales.
- **El percentil:** divide la distribución en 100 partes iguales.

\*Corrección de Bessel

[https://es.wikipedia.org/wiki/Correcci%C3%B3n\\_de\\_Bessel](https://es.wikipedia.org/wiki/Correcci%C3%B3n_de_Bessel)

# Cuartiles

Los cuartiles dividen en cuatro partes las observaciones. El primer cuartil  $Q_1$  es un valor que deje por debajo de él 25% de las y por encima 75% de las observaciones. El  $Q_2$  es la mediana (50%) y  $Q_3$  deja por debajo 75% y por encima 25% de las observaciones





# Medidas de Posición

En este ejemplo utilizamos el método quantile para calcular los cuartiles de un conjunto de datos.

```
1 # Cálculo de los cuartiles
2 q1 = df['BasePay'].quantile(q=.25)
3 q2 = df['BasePay'].quantile(q=.5)
4 q3 = df['BasePay'].quantile(q=.75)
5
6 print('Q1:', q1)
7 print('Q2:', q2)
8 print('Q3:', q3)
```

Q1: 33588.2  
Q2: 65007.45  
Q3: 94691.05

# Sumario de estadísticas

Con el método describe() obtenemos un sumario de estadísticas de la variable, lo cual es un excelente punto de partida para obtener insights.

```
1 # sumario de estadísticas
2 df['BasePay'].describe()
```

```
count    148045.000000
mean      66325.448841
std       42764.635495
min       -166.010000
25%       33588.200000
50%       65007.450000
75%       94691.050000
max       319275.010000
Name: BasePay, dtype: float64
```

Sueldo base negativo??  
**Insight!!!!**




# Histograma

Un histograma permite visualizar la frecuencia de ocurrencia de los distintos valores del conjunto de datos. Esta división se hace en intervalos regulares entre el valor mínimo y máximo del conjunto.

Con este parámetro indicamos la cantidad de intervalos de acumulación

```
1 df['BasePay'].plot(kind='hist', bins=20)
```


<matplotlib.axes.\_subplots.AxesSubplot at 0x19d2579e148>



Otra forma más resumida de generar un histograma

```
1 df['BasePay'].hist(bins=20)
```

<matplotlib.axes.\_subplots.AxesSubplot at 0x19d2542f908>




Nótese que los intervalos de mayor frecuencia se encuentran en torno a los 60 mil dólares, y que también hay un intervalo de valores próximos a cero que tiene una frecuencia alta. **Este puede ser otro insight!!!**

# Diagrama de Distribución

Un diagrama de distribución estima la función de densidad de probabilidad a partir de un conjunto de datos. (KDE: kernel density estimation)


```
1 df['BasePay'].plot(kind='kde')
```

```
<matplotlib.axes._subplots.AxesSubplot at 0x19d25a18248>
```




# Distribución Normal: Curva simétrica

La distribución normal es una de las principales distribuciones, ya que es la que con más frecuencia aparece aproximada en los fenómenos reales. Tiene una forma acampanada y es simétrica respecto de un determinado parámetro estadístico




# Estadística

(a) Sesgada negativamente



(b) Normal (sin sesgo)



(c) Sesgada positivamente





# Boxplot

El boxplot, o diagrama de caja y bigote, entrega información de cómo se distribuyen los valores en un conjunto de datos, identificando también los cuartiles y puntos atípicos.

```
1 df['BasePay'].plot(kind='box')
```

<matplotlib.axes.\_subplots.AxesSubplot at 0x19d25963c88>



# Valores Atípicos


Un valor atípico en un set de datos corresponde a una observación que es numéricamente distantes del resto de los datos, extremadamente grande o extremadamente pequeña. Un valor atípico puede generar un efecto desproporcionado en los resultados estadísticos, como la media, lo cual puede conducir a interpretaciones engañosas.

Un valor atípico, llamado a veces anomalía, podría deberse a un fenómeno único (por ejemplo una lista de clientes de un banco con una persona de 124 años) o bien podría ser producido por un error (por ejemplo tipearon 124 en vez de 24 años al momento de crear al cliente).

Sea cual sea el dato, es conveniente identificar la presencia de valores atípicos o anomalías en los datos.

```
1 df['BasePay'].plot(kind='box')
```

<matplotlib.axes.\_subplots.AxesSubplot at 0x19d25963c88>






# Valores Atípicos

En este caso, los sueldos más altos son distinguidos como valores atípicos, lo cual tiene sentido puesto que hay pocos sueldos muy altos.

```
1 df['BasePay'].plot(kind='box')
```

<matplotlib.axes.\_subplots.AxesSubplot at 0x19d25963c88>



Cálculo de los límites

$$\text{LSUP} = Q3 + 1.5 \cdot \text{IQR}$$

$$\text{LINF} = Q3 - 1.5 \cdot \text{IQR}$$

# Análisis Multivariado

# Análisis Multivariado

El análisis multivariado está referido a las técnicas estadísticas para analizar la data que proviene de más de una variable. A continuación algunos ejemplos de visualizaciones. Para este ejemplo, utilizaremos

```
1 df = pd.read_csv('iris.csv')
```

```
1 df.head()
```


|   | sepal_length | sepal_width | petal_length | petal_width | species |
|---|--------------|-------------|--------------|-------------|---------|
| 0 | 5.1          | 3.5         | 1.4          | 0.2         | setosa  |
| 1 | 4.9          | 3.0         | 1.4          | 0.2         | setosa  |
| 2 | 4.7          | 3.2         | 1.3          | 0.2         | setosa  |
| 3 | 4.6          | 3.1         | 1.5          | 0.2         | setosa  |
| 4 | 5.0          | 3.6         | 1.4          | 0.2         | setosa  |

# Diagrama de Dispersión

Un diagrama de dispersión (boxplot) es una visualización bidimensional que usa puntos para representar los valores de dos variables, una representada en el eje x y otra representada en el eje

y.

```
1 df.plot(kind='scatter',x='petal_length',y='petal_width')  
<matplotlib.axes._subplots.AxesSubplot at 0x19d26d7e948>
```



Como se puede apreciar, hay una correlación entre el largo del pétalo y el ancho. Es decir, en la medida que los pétalos son más largos, también son más anchos.


# Diagrama de Dispersión

A continuación, vamos a utilizar la librería Seaborn para hacer un scatterplot en donde podamos distinguir cada especie de Iris.

```
import seaborn as sns
```

```
1 sns.scatterplot(data=df, x='petal_length', y='petal_width', hue='species')
```

```
<matplotlib.axes._subplots.AxesSubplot at 0x19d285e3688>
```



Como se puede apreciar, esta característica permite separar las distintas especies. Setosa tiene los tamaños más chicos de pétalos mientras que Virginica los más grandes

# Diagrama de Barras

Un diagrama de barras representa datos categóricos, desplegando barras rectangulares con largos proporcionales al valor que representan.


En este caso, representamos el promedio de cada variable para cada una de las especies. Como se puede observar, la especie Virgínica es la que posee en promedio mayor tamaño tanto de largo y ancho del pétalo, así como el largo del sépalo

```
1 df.groupby('species').mean()
```

|            | sepal_length | sepal_width | petal_length | petal_width |
|------------|--------------|-------------|--------------|-------------|
| species    |              |             |              |             |
| setosa     | 5.006        | 3.428       | 1.462        | 0.246       |
| versicolor | 5.936        | 2.770       | 4.260        | 1.326       |
| virginica  | 6.588        | 2.974       | 5.552        | 2.026       |

```
1 df.groupby('species').mean().plot(kind='bar')
```

<matplotlib.axes.\_subplots.AxesSubplot at 0x19d26e30e48>



# Diagrama de Torta

Un diagrama de torta permite una visualización de las proporciones de alguna variable categórica.


En el siguiente ejemplo, visualizamos la proporción de cada especie respecto a la cantidad de mediciones de cada una de ellas.

```
1 df.groupby('species').count()
```

|            | sepal_length | sepal_width | petal_length | petal_width |
|------------|--------------|-------------|--------------|-------------|
| species    |              |             |              |             |
| setosa     | 50           | 50          | 50           | 50          |
| versicolor | 50           | 50          | 50           | 50          |
| virginica  | 50           | 50          | 50           | 50          |

```
1 df.groupby('species').count()['petal_length'].plot(kind='pie', autopct='%.2f%%')
```

<matplotlib.axes.\_subplots.AxesSubplot at 0x19d2a498708>



# Correlación

Hasta ahora nos hemos centrado en medidas de tendencia central, variabilidad y asimetría de una única variable.


No obstante, en la práctica es común examinar dos o más variables conjuntamente (v.g., relación entre inteligencia y rendimiento, etc.)

En este tema nos centraremos en la relación entre 2 variables (a partir de  $n$  observaciones apareadas) y calcularemos (en particular) un índice que nos dará el grado de relación/asociación entre ambas variables: el coeficiente de correlación

Una **correlación** es una medida o grado de relación entre dos variables.




# Representación gráfica de una relación




Nota: El coeficiente de correlación de Pearson mide relación LINEAL.

# Representación gráfica de una relación



Ahora necesitamos un índice que nos informe tanto del grado en que X e Y están relacionadas, y si la relación es positiva o negativa

# Representación gráfica de una relación



# Muestreos aleatorios

Como se ha visto anteriormente, es frecuente la utilización tanto del método `head()` como del método `tail()` para la visualización de algunos registros del dataset. También es posible utilizar el método `sample()` para obtener un conjunto de datos obtenidos de forma aleatoria.

```
df = pd.read_excel('resumen_sueldos.xlsx')  
df.head(2)
```

|   | NOMBRE                           | SUELDO LIQUIDO |
|---|----------------------------------|----------------|
| 0 | Cecilia Del Carmen Ayala Cabrera | 1.803.344      |
| 1 | Jesús Ignacio Contreras Vivar    | 236.489        |

```
df.sample(n=5)
```

|     | NOMBRE                          | SUELDO LIQUIDO |
|-----|---------------------------------|----------------|
| 66  | Debora Andrea Carvallo González | 335.374        |
| 171 | Jocelyn Trinidad Calderón Varas | 1.409.140      |
| 103 | Sergio Ernesto Lillo Rivillo    | 455.346        |
| 119 | María Francisca Olivares Duarte | 139.767        |
| 110 | Carolina Lorena Marín Marín     | 769.306        |

# Muestreos aleatorios

Con el parámetro **frac**, se puede indicar qué fracción de la data se quiere obtener de forma aleatoria. Por defecto, retorna una proporción de filas del dataset, pero con el parámetro `axis=1`, puede retornar un dataframe con columnas seleccionadas de forma aleatoria.

```
df.sample(frac=.05)
```

|     | NOMBRE                                   | SUELDO LIQUIDO |
|-----|------------------------------------------|----------------|
| 71  | Hernán Roberto De Jesús Cataldo Olivares | 2.030.574      |
| 5   | Eugenio Leonardo Hidalgo Araya           | 315.293        |
| 107 | Mariela Maldonado León                   | 2.115.372      |
| 87  | Javier Nicolás Fraser Hernández          | 823.149        |
| 115 | Paola Denyts Núñez Palma                 | 1.161.606      |
| 132 | Fabián Rojas Andrade                     | 197.280        |
| 33  | Eugenio Eliecer Pereira Lazcano          | 669.360        |
| 172 | Valeria Andrea Céspedes Vilches          | 448.028        |
| 110 | Carolina Lorena Marín Marín              | 769.306        |

# Python Librerías para estadística

- **numpy**: El popular paquete matemático de [Python](#), se utiliza tanto que mucha gente ya lo considera parte integral del lenguaje. Nos proporciona algunas funciones estadísticas que podemos aplicar fácilmente sobre los *arrays* de [Numpy](#).
- **scipy.stats**: Este submodulo del paquete científico [Scipy](#) es el complemento perfecto para [Numpy](#), las funciones estadísticas que no encontremos en uno, las podemos encontrar en el otro.
- **statsmodels**: Esta librería nos brinda un gran número de herramientas para explorar [datos](#), estimar modelos estadísticos, realizar pruebas estadísticas y muchas cosas más.
- **matplotlib**: Es la librería más popular en [Python](#) para visualizaciones y gráficos. Ella nos va a permitir realizar los gráficos de las distintas distribuciones de datos.
- **seaborn**: Esta librería es un complemento ideal de [matplotlib](#) para realizar gráficos estadísticos.
- **pandas**: Esta es la librería más popular para análisis de [datos](#) y financieros. Posee algunas funciones muy útiles para realizar [estadística descriptiva](#) sobre nuestros datos y nos facilita sobremanera el trabajar con [series de tiempo](#).
- **pyMC**: [pyMC](#) es un módulo de [Python](#) que implementa modelos estadísticos bayesianos, incluyendo la [cadena de Markov Monte Carlo\(MCMC\)](#). [pyMC](#) ofrece funcionalidades para hacer el análisis bayesiano lo mas simple posible.

Gracias