



# Aprendizaje Supervisado

Modelos de Machine Learning

# Tipos y tareas de machine learning





## ¿Y qué preguntas?

- ¿Podemos predecir quiénes son tus amigos?
- ¿Podemos predecir qué publicidad o contenido estarías interesado?

# ¿Y qué preguntas?

**Nicholas Carlson (Me)**  
Silicon Alley Insider · Davidson

**Nick O'Neill**  
Social Times, Inc. · American

**Nick Denton**  
Gawker Media · New York, New York

**Nicole Schumacher**  
Columbia · New York, New York

**Nick Bilton**  
The New York Times Company · San Francisco, California

**Angela Nibbs**  
maven · San Francisco, California

**Nicholas Saint**  
Haverford · Brooklyn, New York

**Barrett Nichols**

**Nicholas Carlson**  
January 23 via Instagram

SAI! <http://instagr.am/p/kCxOr/>

Done Tagging Add Location Edit

Like · Comment · Unfollow Post · Share · Edit

Danielle Lacombe and Owen Thomas like this.

**Owen Thomas Nerds.**  
January 23 at 6:35pm · Like · 1

Write a comment...

**Sponsored**

Mazyar Kazerooni likes Dewar's.

**Dewar's**  
Like

Justin Smith likes Target.

**Target**  
Like

Everything is a Recommendation



NETFLIX

Over 80% of what people watch comes from our recommendations

Recommendations are driven by Machine Learning


¿Y qué preguntas?

¿Podemos predecir qué película de seguro te gustará?


¿Y qué preguntas?

amazon

ebay



¿Podemos predecir qué artículo de seguro te interesará?



## House price prediction

Predicting the house price




Shree • updated 2 years ago (Version 2)

| A               | B         | C        | D         | E           | F        | G      | H          | I    | J         | K          | L          | M        |
|-----------------|-----------|----------|-----------|-------------|----------|--------|------------|------|-----------|------------|------------|----------|
| date            | price     | bedrooms | bathrooms | sqft_living | sqft_lot | floors | waterfront | view | condition | sqft_above | sqft_basem | yr_built |
| 02-05-2014 0:00 | 313000.0  | 3.0      | 1.5       | 1340        | 7912     | 1.5    | 0          | 0    | 3         | 1340       | 0          | 1955     |
| 02-05-2014 0:00 | 2384000.0 | 5.0      | 2.5       | 3650        | 9050     | 2.0    | 0          | 4    | 5         | 3370       | 280        | 1921     |
| 02-05-2014 0:00 | 342000.0  | 3.0      | 2.0       | 1930        | 11947    | 1.0    | 0          | 0    | 4         | 1930       | 0          | 1966     |
| 02-05-2014 0:00 | 420000.0  | 3.0      | 2.25      | 2000        | 8030     | 1.0    | 0          | 0    | 4         | 1000       | 1000       | 1963     |
| 02-05-2014 0:00 | 550000.0  | 4.0      | 2.5       | 1940        | 10500    | 1.0    | 0          | 0    | 4         | 1140       | 800        | 1976     |
| 02-05-2014 0:00 | 490000.0  | 2.0      | 1.0       | 880         | 6380     | 1.0    | 0          | 0    | 3         | 880        | 0          | 1938     |
| 02-05-2014 0:00 | 335000.0  | 2.0      | 2.0       | 1350        | 2560     | 1.0    | 0          | 0    | 3         | 1350       | 0          | 1976     |
| 02-05-2014 0:00 | 482000.0  | 4.0      | 2.5       | 2710        | 35868    | 2.0    | 0          | 0    | 3         | 2710       | 0          | 1989     |
| 02-05-2014 0:00 | 452500.0  | 3.0      | 2.5       | 2430        | 88426    | 1.0    | 0          | 0    | 4         | 1570       | 860        | 1985     |
| 02-05-2014 0:00 | 640000.0  | 4.0      | 2.0       | 1520        | 6200     | 1.5    | 0          | 0    | 3         | 1520       | 0          | 1945     |
| 02-05-2014 0:00 | 463000.0  | 3.0      | 1.75      | 1710        | 7320     | 1.0    | 0          | 0    | 3         | 1710       | 0          | 1948     |
| 02-05-2014 0:00 | 1400000.0 | 4.0      | 2.5       | 2920        | 4000     | 1.5    | 0          | 0    | 5         | 1910       | 1010       | 1909     |
| 02-05-2014 0:00 | 588500.0  | 3.0      | 1.75      | 2330        | 14892    | 1.0    | 0          | 0    | 3         | 1970       | 360        | 1980     |
| 02-05-2014 0:00 | 365000.0  | 3.0      | 1.0       | 1090        | 6435     | 1.0    | 0          | 0    | 4         | 1090       | 0          | 1955     |
| 02-05-2014 0:00 | 1200000.0 | 5.0      | 2.75      | 2910        | 9480     | 1.5    | 0          | 0    | 3         | 2910       | 0          | 1939     |
| 02-05-2014 0:00 | 242500.0  | 3.0      | 1.5       | 1200        | 9720     | 1.0    | 0          | 0    | 4         | 1200       | 0          | 1965     |
| 02-05-2014 0:00 | 419000.0  | 3.0      | 1.5       | 1570        | 6700     | 1.0    | 0          | 0    | 4         | 1570       | 0          | 1956     |
| 02-05-2014 0:00 | 367500.0  | 4.0      | 3.0       | 3110        | 7231     | 2.0    | 0          | 0    | 3         | 3110       | 0          | 1997     |

Aprendizaje  
Supervisado

# Supervised Learning

## Housing price prediction.



Es **supervisado**, porque ya se tienen “respuestas correctas”.

Es un problema de **Regresión**, porque se predicen valores continuos.


# Ejemplos de Sistemas ML

Los mails SPAM son cada día más molestos.

**El Problema:** Queremos identificar cuando un correo que llega a una cuenta corresponde a SPAM.


Es un problema de **Clasificación**, porque se predicen valores discretos.





## Ejemplos de Sistemas ML

### Visual Recognition



# Pregunta

Eres científico de datos en una compañía y te piden que desarrolles un algoritmo para resolver los siguientes problemas:

1. Hay una gran cantidad de productos en stock, y se desea predecir cuántos ítems serán vendidos durante los siguientes tres meses.
2. Desarrollar un software que permita examinar las cuentas de los clientes para determinar si han sido hackeadas o no.


¿Clasificación o  
Regresión?

# Problemas Regresivos

# ¿Qué es una tarea de regresión?



Supongamos que tenemos información histórica de los precios de bienes raíces de la ciudad, y lo que queremos es realizar un modelo que nos permita predecir el valor de una propiedad a partir de sus características.



| A               | B         | C        | D         | E           | F        | G      | H          | I    | J         | K          | L             | M        |
|-----------------|-----------|----------|-----------|-------------|----------|--------|------------|------|-----------|------------|---------------|----------|
| date            | price     | bedrooms | bathrooms | sqft_living | sqft_lot | floors | waterfront | view | condition | sqft_above | sqft_basement | yr_built |
| 02-05-2014 0:00 | 313000.0  | 3.0      | 1.5       | 1340        | 7912     | 1.5    | 0          | 0    | 3         | 1340       | 0             | 1955     |
| 02-05-2014 0:00 | 2384000.0 | 5.0      | 2.5       | 3650        | 9050     | 2.0    | 0          | 4    | 5         | 3370       | 280           | 1921     |
| 02-05-2014 0:00 | 342000.0  | 3.0      | 2.0       | 1930        | 11947    | 1.0    | 0          | 0    | 4         | 1930       | 0             | 1966     |
| 02-05-2014 0:00 | 420000.0  | 3.0      | 2.25      | 2000        | 8030     | 1.0    | 0          | 0    | 4         | 1000       | 1000          | 1963     |
| 02-05-2014 0:00 | 550000.0  | 4.0      | 2.5       | 1940        | 10500    | 1.0    | 0          | 0    | 4         | 1140       | 800           | 1976     |
| 02-05-2014 0:00 | 490000.0  | 2.0      | 1.0       | 880         | 6380     | 1.0    | 0          | 0    | 3         | 880        | 0             | 1938     |
| 02-05-2014 0:00 | 335000.0  | 2.0      | 2.0       | 1350        | 2560     | 1.0    | 0          | 0    | 3         | 1350       | 0             | 1976     |
| 02-05-2014 0:00 | 482000.0  | 4.0      | 2.5       | 2710        | 35868    | 2.0    | 0          | 0    | 3         | 2710       | 0             | 1989     |
| 02-05-2014 0:00 | 452500.0  | 3.0      | 2.5       | 2430        | 88426    | 1.0    | 0          | 0    | 4         | 1570       | 860           | 1985     |
| 02-05-2014 0:00 | 640000.0  | 4.0      | 2.0       | 1520        | 6200     | 1.5    | 0          | 0    | 3         | 1520       | 0             | 1945     |
| 02-05-2014 0:00 | 463000.0  | 3.0      | 1.75      | 1710        | 7320     | 1.0    | 0          | 0    | 3         | 1710       | 0             | 1948     |
| 02-05-2014 0:00 | 1400000.0 | 4.0      | 2.5       | 2920        | 4000     | 1.5    | 0          | 0    | 5         | 1910       | 1010          | 1909     |
| 02-05-2014 0:00 | 588500.0  | 3.0      | 1.75      | 2330        | 14892    | 1.0    | 0          | 0    | 3         | 1970       | 360           | 1980     |
| 02-05-2014 0:00 | 365000.0  | 3.0      | 1.0       | 1090        | 6435     | 1.0    | 0          | 0    | 4         | 1090       | 0             | 1955     |
| 02-05-2014 0:00 | 1200000.0 | 5.0      | 2.75      | 2910        | 9480     | 1.5    | 0          | 0    | 3         | 2910       | 0             | 1939     |
| 02-05-2014 0:00 | 242500.0  | 3.0      | 1.5       | 1200        | 9720     | 1.0    | 0          | 0    | 4         | 1200       | 0             | 1965     |
| 02-05-2014 0:00 | 419000.0  | 3.0      | 1.5       | 1570        | 6700     | 1.0    | 0          | 0    | 4         | 1570       | 0             | 1956     |
| 02-05-2014 0:00 | 367500.0  | 4.0      | 3.0       | 3110        | 7231     | 2.0    | 0          | 0    | 3         | 3110       | 0             | 1997     |

# ¿Qué es una tarea de regresión?

- Una tarea de regresión es aquella que realiza el proceso de predicción de una cantidad (Y), a partir de sus **features** (X)

Target (Y)

Features (X)



| B         | C        | D         | E           | F        | G      | H          | I    | J         | K          | L          | M        |
|-----------|----------|-----------|-------------|----------|--------|------------|------|-----------|------------|------------|----------|
| price     | bedrooms | bathrooms | sqft_living | sqft_lot | floors | waterfront | view | condition | sqft_above | sqft_basem | yr_built |
| 313000.0  | 3.0      | 1.5       | 1340        | 7912     | 1.5    | 0          | 0    | 3         | 1340       | 0          | 1955     |
| 2384000.0 | 5.0      | 2.5       | 3650        | 9050     | 2.0    | 0          | 4    | 5         | 3370       | 280        | 1921     |
| 342000.0  | 3.0      | 2.0       | 1930        | 11947    | 1.0    | 0          | 0    | 4         | 1930       | 0          | 1966     |

- La variable **target**, corresponde a una variable numérica real, que puede ser entera o decimal.

# Tipos de Regresión




Existen varios tipos de regresión que nos permiten resolver tareas de este tipo, dentro de los cuales se encuentran:

- Regresiones Lineales Simples.
- Regresiones Lineales Multivariadas.
- Regresiones Polinomiales.
- Series de Tiempo.
- Otras...

# Tipos de Regresión




El siguiente, es un ejemplo de una **Regresión Lineal Simple**. Es simple, porque utiliza sólo un feature (superficie) y es lineal porque en este modelo el precio responde de forma lineal respecto a la superficie.



¿Podría predecir el precio de una propiedad de 750 ft²?

# Tipos de Regresión


- El siguiente, es un ejemplo de una **Regresión Polinomial**. Nótese que la respuesta del precio es no lineal respecto a la superficie en dicho modelo.



# Tipos de Regresión




El siguiente, también es un ejemplo de una **Regresión Polinomial**. Nótese este modelo tiene un nivel de complejidad mayor que los anteriores y podría, por lo tanto, presentar sobreajuste.



# Tipos de Regresión




Lo mismo este modelo **Regresivo No Lineal**, otro ejemplo.



# Tipos de Regresión



El siguiente gráfico, corresponde a una Serie de Tiempo. Nótese que en el eje X el feature corresponde a la variable Tiempo, y en el eje Y se encuentra el valor de la serie. En una serie de tiempo, los modelos predictivos se les llama pronósticos.



# Algoritmos de Regresión



Hay múltiples algoritmos para resolver problemas regresivos, a continuación se mencionan algunos:

- Regresión Lineal OLS.
- Regresión Lasso y Ridge.
- Árboles Regresivos.
- Support Vector Regression.
- Redes Neuronales.

# Problemas de Clasificación

# ¿Qué es una tarea de clasificación?

Una tarea de clasificación es aquella que realiza el proceso de predicción de una clase o categoría (Y), a partir de sus features (X).

Diagram illustrating a classification task using a dataset table.

The table is divided into two main sections:

- Features (X):** Indicated by a bracket above the first six columns: `deuda_total`, `tipo_empleo`, `cuentas_abiertas`, `historial_credito`, `historial_credito_anios`, and `mora_reciente`.
- Target (Y):** Indicated by an arrow pointing to the `riesgo` column.


The data rows represent historical training data:

| deuda_total | tipo_empleo   | cuentas_abiertas | historial_credito | historial_credito_anios | mora_reciente | riesgo |
|-------------|---------------|------------------|-------------------|-------------------------|---------------|--------|
| 35946       | fijo          | 4                | regular           | 12                      | 0             | 1      |
| 55204       | fijo          | 3                | bueno             | 7                       | 0             | 0      |
| 51886       | eventual      | 2                | regular           | 13                      | 0             | 0      |
| 71652       | fijo          | 4                | bueno             | 0                       | 0             | 0      |
| 15563       | fijo          | 5                | bueno             | 16                      | 0             | 0      |
| ...         | ...           | ...              | ...               | ...                     | ...           | ...    |
| 74071       | fijo          | 5                | bueno             | 0                       | 0             | 0      |
| 57326       | independiente | 5                | bueno             | 14                      | 0             | 0      |

A red box highlights the `riesgo` column, which represents the target variable. A grey box labeled "Datos históricos o de entrenamiento" (Historical or training data) covers the first six columns of the data rows.

Entonces, para este caso, la tarea consiste en predecir qué personas tiene diabetes (Y) correspondería clasificar esta instancia de datos (X).

# Aprendizaje supervisado



Definir modelo

Entrenar modelo

Hacer predicciones

Evaluar resultados

| deuda_total | tipo_empleo   | cuentas_abiertas                       | historial_credito | historial_credito_anios | mora_reciente | riesgo |
|-------------|---------------|----------------------------------------|-------------------|-------------------------|---------------|--------|
| 35946       | fijo          | 4                                      | regular           | 12                      |               | 1      |
| 55204       | fijo          | 3                                      | bueno             | 7                       |               | 0      |
| 51886       | eventual      | 2                                      | regular           | 13                      |               | 0      |
| 71652       | fijo          | Datos históricos<br>o de entrenamiento |                   | 0                       |               | 0      |
| 15563       | fijo          |                                        |                   | 16                      |               | 0      |
| ...         | ...           |                                        |                   | ...                     |               | ...    |
| 74071       | fijo          | 5                                      | bueno             | 0                       |               | 0      |
| 57326       | independiente | 5                                      | bueno             | 14                      |               | 0      |
| 90023       | fijo          | 5                                      | regular           | 18                      |               | 0      |
| 30651       | fijo          | 4                                      | bueno             | 3                       | 0             | 0      |

| deuda_total | tipo_empleo | cuentas_abiertas                        | historial_credito | historial_credito_anios | mora_reciente | riesgo |
|-------------|-------------|-----------------------------------------|-------------------|-------------------------|---------------|--------|
| 35946       | fijo        | Nuevos datos<br>(sin variable objetivo) |                   | 12                      |               | 1      |
| 55204       | fijo        |                                         |                   | 7                       |               | 0      |
| 51886       | eventual    |                                         |                   | 13                      |               | 0      |
| 71652       | fijo        | 3                                       | bueno             | 0                       |               | 1      |
| 15563       | fijo        | 2                                       | regular           | 16                      |               | 1      |

Modelo  
entrenado

Predicción

# ¿Qué es entrenar un modelo?

## Ejemplo: Regresión logística

Se busca predecir la **probabilidad** ( $p$ ) de que una observación pertenezca a una categoría, a través de regresión lineal

$$\ln \left( \frac{p}{1-p} \right) = \beta_0 + \sum_{i=1}^k \beta_i x_i$$

log-odds

Regresión lineal con variables independientes


**Entrenar** un modelo es determinar sus parámetros a partir de los datos históricos.

En este caso, es determinar los coeficientes de la regresión

$p$ : probabilidad de que una persona tenga diabetes

# Modelo de Clasificación

Para elaborar un modelo de clasificación, que retorne valores discretos 0 o 1, simplemente definimos un punto de corte en 0.5, es decir. Todo valor sobre 0.5 se aproxima a 1, y todo valor bajo 0.5 se aproxima a 0.



Evaluar resultados

Para datos en los que conocemos el valor de la variable objetivo, podemos evaluar el poder predictivo del modelo


Predicción

| riesgo |
|--------|
| 1      |
| 0      |
| 0      |
| 0      |
| 0      |
| ...    |
| 0      |
| 0      |
| 0      |

VS

Valor real

| riesgo |
|--------|
| 1      |
| 0      |
| 0      |
| 0      |
| 0      |
| 0      |
| ...    |
| 0      |
| 0      |
| 0      |



# ¿Qué es una tarea de clasificación?

- Se habla de **clasificación binaria**, si la variable objetivo (Y) tiene solamente dos categorías posibles (por ejemplo: True/False, Si/No).
- Por otra parte, se habla de una **clasificación multi-clase** si la variable objetivo (Y) tiene más de dos categorías posibles (por ejemplo: Virginica, Versicolor, Setosa).
- Por último, se habla de una clasificación **multi-etiqueta** cuando una instancia pudiera estar asociada a más de una clase o categoría.

# Ejercicio – Relacione el concepto

- 1** A partir de los textos de un correo electrónico, se desea entrenar un algoritmo que pueda determinar si un correo es spam.
- 2** A partir de la información demográfica y la cantidad de veces que un cliente ha sido expuesto a una publicidad, queremos saber si un cliente realizará una compra.
- 3** A partir de una fotografía del rostro de una persona, deseamos saber cuál es su nombre.
- 4** A partir de información de temperatura, humedad, presión atmosférica y velocidad del viento, queremos predecir cómo estará el clima el día de mañana.
- 5** A partir de un texto, queremos clasificar los tópicos al cual pertenece.
- 6** A partir de la información de cantidad de habitaciones, sector, metros cuadrados, cercanía al metro, dependencias, ubicación, año y material de construcción, queremos predecir el precio de un bien raíz.

Clasificación  
Binaria

Clasificación  
Multi-clase

Clasificación  
Multi-etiqueta

Ninguna de las  
anteriores

# Algoritmos de Clasificación

➤ Los algoritmos de clasificación son programas computacionales que están diseñados para encontrar modelos predictivos a partir de un set de datos de ejemplo. Dentro de los más populares, se pueden mencionar los siguientes:

- Regresión Logística.
- K-Nearest Neighbors.
- Árboles de Decisión.
- Máquinas de Soporte Vectorial.
- Naive Bayes.
- Redes Neuronales.


➤ Algunos de ellos, como la regresión logística y la máquina de soporte vectorial, están diseñados para clasificación binaria y de forma nativa no soportan clasificación multi-clases.

# Métricas de desempeño

Una **métrica de clasificación** es simplemente un número que mide el performance del modelo de aprendizaje de máquina que fue entrenado previamente en la labor de asignar clases o categorías a nuevas mediciones.

Típicamente, este valor se encuentra entre 0 y 1, donde un score de 1 corresponde a un modelo perfecto.

Existen varias métricas de desempeño que pueden ser utilizada, cada una de ellas tiene sus ventajas e inconvenientes.



## Evaluar resultados

En el caso de modelos de clasificación...

$Y = 0$

NOT PREGNANT

$Y = 1$

PREGNANT

$\hat{Y} = 0$

NEGATIVE



$\hat{Y} = 1$

POSITIVE



# Matriz de confusión

## Evaluar resultados

En el caso de modelos de clasificación...

$Y = 0$

NOT PREGNANT

$Y = 1$

PREGNANT

TRUE NEGATIVE

You're not pregnant

FALSE NEGATIVE

You're not pregnant

TYPE 2 ERROR

FALSE POSITIVE

You're pregnant

TYPE 1 ERROR

TRUE POSITIVE

You're pregnant

$\hat{Y} = 0$   
NEGATIVE

$\hat{Y} = 1$   
POSITIVE

$$precision = \frac{TP}{TP + FP}$$

$$recall = \frac{TP}{TP + FN}$$

$$accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

# ¿Qué opinan de este modelo?

**Ejemplo diabetes:** Usando los mismos datos de entrenamiento para evaluar

| Predicción | Real      |           |
|------------|-----------|-----------|
|            | No riesgo | Sí riesgo |
| No riesgo  | 233       | 56        |
| Sí riesgo  | 29        | 74        |

$$precision = \frac{TP}{TP + FP}$$

$$recall = \frac{TP}{TP + FN}$$



Trabajen en  
grupos (5 mins)

$$accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

# Accuracy

Es la métrica más utilizada al momento de evaluar un modelo predictivo, simplemente consiste en la proporción de aciertos que tuvo el modelo respecto de la cantidad total de predicciones.

$$Accuracy = \frac{Total\ de\ Aciertos}{Total\ de\ Predicciones}$$


Comente: ¿Es bueno o malo un Accuracy de 60%?

Comente: ¿Es bueno o malo un Accuracy de 60%?

!!!Depende del contexto del  
problema!!!!

# ¿Por qué es importante el tipo de error?


Supongamos que estamos elaborando un modelo que predice si un asteroide chocará con el planeta tierra dentro de los próximos 3 meses o no, con un accuracy de 99%.



¿Es suficiente esta métrica?


# Pero, ¿tiene sentido evaluar un modelo usando los mismos datos de entrenamiento?

Yo evaluando el modelo sobre los mismos datos de entrenamiento



# Una mejor manera: Cross-validation (validación cruzada)

Yo evaluando el modelo sobre  
los mismos datos de entrenamiento



Se dividen (aleatoriamente) los datos en datos de **entrenamiento** y **testeo**. **Sólo** se entrena el modelo con los datos de entrenamiento y **sólo** se evalúa con los datos de **testeo**.

# ¿Qué es la validación cruzada?

- La validación cruzada (cross validation) es una técnica utilizada para evaluar los resultados de un análisis estadístico y garantizar que son independientes de la partición entre datos de entrenamiento y prueba. Se utiliza en entornos en donde el objetivo principal es la predicción y se quiere estimar la precisión de un modelo que se llevará a cabo a la práctica. Esta técnica es muy utilizada en inteligencia artificial y aprendizaje de máquina.
- En la elaboración de un modelo predictivo, se corre el riesgo que el modelo sea demasiado dependiente de los datos con el cual fue confeccionado, los cuales podrían no representar del todo la realidad. Es por esto que se utiliza validación cruzada, para verificar que los modelos tendrán un buen poder de generalización, es decir no tienen una fuerte dependencia de los datos con los cuales fueron entrenados.

## ¿Qué es la validación cruzada?

Esta técnica puede ser aplicada de muchas maneras, las más conocidas son las siguientes:

- Método de retención.
- Validación cruzada de k-iteraciones.
- Validación cruzada aleatoria.
- Validación cruzada dejando uno afuera.

# Método de retención

Es el mecanismo de validación cruzada más simple de todos, en donde tomamos el set de datos disponible y lo dividimos en un set de entrenamiento y en otro set de validación.



Set de Entrenamiento

70% - 80% aprox.


Set de Validación

20% - 30% aprox.

# Y todavía mejor...

Evitamos ser víctimas de una mala/buena elección del test set

## K-fold Cross validation




## Nivel de Ajuste de un Modelo

# Nivel de Ajuste del Modelo


El modelo no ha capturado la lógica subyacente de los datos.



Underfit




Optimal



El modelo se concentró demasiado en los datos de entrenamiento pero “perdió el foco”.




Overfit



Más que un modelo que tenga ajuste perfecto, lo que se busca es un modelo que tenga buena **capacidad de generalización**.

# Nivel de Ajuste del Modelo


A continuación, se presentan 3 escenarios de ajuste de un modelo de clasificación:  
**Subajustado, óptimo y sobreajustado.**



Más que un modelo que tenga ajuste perfecto, lo que se busca es un modelo que tenga buena **capacidad de generalización**.


# Desviación v/s Varianza

Cuando ajustamos un modelo de machine learning tratamos que sea lo más preciso, sin embargo, nunca estará libre de errores.



# Desviación v/s Varianza

Comprender la desviación y la varianza es fundamental, pero lo que realmente importa es el error general.



Un buen modelo es aquel que encuentra un **buen equilibrio** entre **desviación y varianza** de manera de minimizar el error total.

# Desviación v/s Varianza

Un modelo con ajuste apropiado tiene baja desviación y baja varianza.

