


Regresiones Lineales Simples

Francis Galton

(Inglaterra, 1822 – 1911)

Creó el concepto estadístico de correlación y regresión hacia la media, altamente promovido.

Él fue el primero en aplicar métodos estadísticos para el estudio de las diferencias humanas y la herencia de la inteligencia, introdujo el uso de cuestionarios y encuestas para recoger datos sobre las comunidades humanas, que necesitaba para trabajos genealógicos y biográficos y para sus estudios antropométricos.



Francis Galton

Dentro de otras cosas, estudió la relación que existe entre la altura de padres y sus hijos, llegando a la conclusión que los hijos son levemente más altos que sus padres.



Francis Galton



No obstante, descubrió que la altura de los hijos tendía a estar más cerca a la altura media de todas las personas.

Por ejemplo, el hijo de Shaquille O'Neal, Shareef, es alto, pero no es tan alto como Shaq.

Experimento

1. Realicemos mediciones de la altura de padres e hijos y tabulemos los datos.
2. Hagamos análisis exploratorio de los datos.
3. A partir de los datos, elaboremos un modelo que nos permita realizar una predicción de la altura de un hijo a partir de la altura del padre.

Obtenemos los datos

```
import pandas as pd
import seaborn as sns
```

```
df = pd.read_csv('Galton.txt', sep='\t')
```

Nótese que en este caso, el archivo viene separado por tabulaciones. En este caso, se debe indicar el parámetro **sep** al momento de realizar la lectura.

Galton.txt: Bloc de notas

Archivo	Edición	Formato	Ver	Ayuda	
Family	Father	Mother	Gender	Height	Kids
1	78.5	67	M	73.2	4
1	78.5	67	F	69.2	4
1	78.5	67	F	69	4
1	78.5	67	F	69	4
2	75.5	66.5	M	73.5	4
2	75.5	66.5	M	72.5	4
2	75.5	66.5	F	65.5	4
2	75.5	66.5	F	65.5	4
3	75	64	M	71	2
3	75	64	F	68	2
4	75	64	M	70.5	5
4	75	64	M	68.5	5
4	75	64	F	67	5
4	75	64	F	64.5	5
4	75	64	F	63	5
5	75	58.5	M	72	6
5	75	58.5	M	69	6
5	75	58.5	M	68	6
5	75	58.5	F	66.5	6
5	75	58.5	F	62.5	6
5	75	58.5	F	62.5	6
6	74	68	F	69.5	1
7	74	68	M	76.5	6
7	74	68	M	74	6
7	74	68	M	73	6
7	74	68	M	73	6
7	74	68	F	70.5	6
7	74	68	F	64	6

Exploramos los datos

```
df.head()
```

	Family	Father	Mother	Gender	Height	Kids
0	1	78.5	67.0	M	73.2	4
1	1	78.5	67.0	F	69.2	4
2	1	78.5	67.0	F	69.0	4
3	1	78.5	67.0	F	69.0	4
4	2	75.5	66.5	M	73.5	4


```
df.shape
```

```
(898, 6)
```

```
df.groupby('Gender').count()
```


	Family	Father	Mother	Height	Kids
Gender					
F	433	433	433	433	433
M	465	465	465	465	465

```
sns.pairplot(data=df, hue='Gender')
```




Qué es un modelo regresivo lineal

Realizaremos una regresión lineal, es decir, trazaremos una línea recta que se ajuste de la mejor forma.



Qué es un modelo regresivo lineal


El objetivo de la Regresión Lineal es obtener la línea recta en donde se **minimice la suma de todas las distancias verticales** entre los puntos y la línea.



Qué es un modelo regresivo lineal

Utilizaremos el método de los mínimos cuadrados para ajustar la línea recta.


Es decir, obtendremos la línea recta que minimice la suma de los cuadrados de los residuos.



Qué es un modelo regresivo lineal

Utilizaremos el método de los mínimos cuadrados para ajustar la línea recta.

Es decir, obtendremos la línea recta que minimice la suma de los cuadrados de los residuos.



Regresión Lineal

The diagram illustrates the components of the linear regression equation $y = b_0 + b_1 x_1 + err$. It features five labels with arrows pointing to specific parts of the equation:


- Intercepto**: Points to the term b_0 .
- Coeficiente**: Points to the term b_1 .
- Variable Dependiente**: Points to the variable y .
- Variable Independiente**: Points to the variable x_1 .
- Error**: Points to the term err .

The equation is displayed as follows:

$$y = b_0 + b_1 x_1 + err$$

Regresión Lineal


$$\textit{Altura Hijo} = b_0 + b_1 \textit{Altura Padre}$$




Regresión Lineal

Modelo:

$$\textit{Altura Hijo} = b_0 + b_1 \textit{Altura Padre}$$



Regresión Lineal



$$\min \sum_{i=0}^m (y_i - \hat{y}_i)^2$$

Regresión Lineal


Modelo:

$$\textit{Altura Hijo} = b_0 + b_1 \textit{Altura Padre}$$

¿Cómo obtener los valores de b_0 y b_1 que minimicen el error?

Mínimos Cuadrados– Encontrando la mejor línea

Mínimos cuadrados es un método estadístico que se utiliza para determinar la línea de mejor ajuste o la línea de regresión minimizando la suma de cuadrados creada por una función matemática. El "cuadrado" aquí se refiere a elevar al cuadrado la distancia entre un punto de datos y la línea de regresión. La línea con el valor mínimo de la suma del cuadrado es la línea de regresión que mejor se ajusta.




Mínimos Cuadrados– Encontrando la mejor línea

Regression Line, $y = mx + c$ where,

y = Dependent Variable

x = Independent Variable ; c = y-Intercept

$$m = \frac{\sum (x - \bar{x})(y - \bar{y})}{\sum (x - \bar{x})^2}$$




Estableciendo la Hipótesis de Trabajo

En este modelo vamos a establecer una relación **entre el tamaño de la hija a partir del tamaño de la madre**. Por lo tanto, se requiere generar un nuevo dataframe con valores filtrados.

Nótese que en este caso estamos formulando un modelo regresivo simple, es decir, utilizaremos un solo predictor (feature).

```
df_f = df[ df['Gender']=='F' ]
```

```
sns.jointplot(data=df_f, x='Mother', y='Height')
```



Formulación del Modelo

Definiremos nuestra matriz de features (X) y nuestro vector de resultado (y). Nótese que en este caso, la matriz X tiene una sola columna.

In [8]:

```
1 X = df_f[['Mother']]  
2 y = df_f['Height']
```

In [9]:

```
1 X.head(2)
```

Out[9]:

	Mother
1	67.0
2	67.0

Validación Cruzada

Como es habitual, dividiremos el set de datos en set de entrenamiento y en set de test.

```
: 1 from sklearn.model_selection import train_test_split
```

```
: 1 X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)
```

```
: 1 print(X_train.shape)  
  2 print(X_test.shape)
```

```
(346, 1)
```

```
(87, 1)
```

Entrenamiento del modelo

A continuación, realizaremos el entrenamiento del modelo lineal importando la clase `LinearRegression` desde `scikit-learn`.

```
1 from sklearn.linear_model import LinearRegression
```

```
1 lm = LinearRegression()  
2 lm.fit(X_train,y_train)
```

`LinearRegression()`

Nótese que el modelo
entrenado quedó
almacenado en la variable **lm**

Nótese que el entrenamiento lo
realizamos sobre el training set

```
1 # coeficientes ajustados  
2 lm.coef_
```

`array([0.32561679])`

Este es el valor del coeficiente que
determinó el algoritmo

```
1 # intercepto  
2 lm.intercept_
```

`43.17026674816181`

Este es el valor del intercepto que
determinó el algoritmo

Realizando algunas predicciones

Con nuestro modelo lineal ya podemos realizar algunas predicciones, ya sea sobre un valor, varios valores, o todo el set de test.

```
1 # predicciones sobre un valor
2 p1 = [[62]]
3 lm.predict(p1)
```

```
array([63.35850788])
```

```
1 # predicciones sobre varios valores
2 p2 = [[50],
3       [55],
4       [60],
5       [65],
6       [70]]
7 lm.predict(p2)
```

```
array([59.45110637, 61.07919033, 62.70727429, 64.33535826, 65.96344222])
```

```
1 # predicciones sobre el set de test
2 y_pred = lm.predict(X_test)
```

```
1 y_pred[:5]
```

```
array([64.05480614, 64.70791076, 63.72825384, 64.38135845, 64.70791076])
```

```
1 y_test[:5]
```

```
881    60.0
137    66.5
357    64.0
54     64.5
765    65.5
Name: Height, dtype: float64
```

Comprobando la hipótesis de Galton

Nótese que si calculamos la media de las alturas de hijas de la población, nos arroja un valor de 64.11 pulgadas. Esto comprueba lo que Galton le llamó “regresión hacia la media”, puesto que si una madre tiene una altura baja, digamos 50 pulgadas, la altura de su hija tenderá hacia la media, es decir, tendrá una altura mayor. Pero si la altura de la madre es de 70 pulgadas, la altura de la hija será mejor, tendiendo hacia la media de la población.

```
1 # el promedio de altura de las hijas mujeres
2 df_f['Height'].mean()
```

```
64.11016166281759
```

```
1 # predicciones sobre varios valores
2 p2 = [[50],
3        [55],
4        [60],
5        [65],
6        [70]]
7 lm.predict(p2)
```

```
array([59.45110637, 61.07919033, 62.70727429, 64.33535826, 65.96344222])
```

Métricas de evaluación de regresiones


En una regresión lineal, las métricas de evaluación están enfocadas a cuantificar el error del modelo respecto a los valores reales en el set de datos donde realizamos la validación. Existen varias métricas de error, pero las más utilizadas son las siguientes:

- Mean Absolute Error (MAE)
- Mean Squared Error (MSE)
- Root Mean Squared Error (RMSE)

(MAE) Mean Absolute Error

Es la métrica más sencilla de todas para medir el error de un modelo regresivo, corresponde a la suma de las diferencias absolutas entre el valor predicho y el valor real dividido por la cantidad de mediciones.


$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$



(MSE) Mean Squared Error


Es similar a la métrica anterior, también sirve para medir el error de un modelo regresivo, sin embargo corresponde a la suma de las diferencias cuadradas entre el valor predicho y el valor real dividido por la cantidad de mediciones

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$




MAE v/s MSE

Para ilustrar la diferencia, veamos los siguientes ejemplos.



MAE = _____ MSE = _____



MAE = _____ MSE = _____


MAE v/s MSE

La métrica MSE castiga más a los modelos que tienen puntos con alto error, sin embargo esta métrica está en unidades al cuadrado.

(RMSE) Root Mean Squared Error

Dado que el MSE tiene una unidad de medida elevada al cuadrado, lo cual hace que la métrica a veces no se comprenda, simplemente extraemos la raíz cuadrada para obtener el RMSE.

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$



Métricas de evaluación de regresiones

Para utilizar las funciones de métricas de evaluación de la regresión, debemos importar la librería **metrics**.

```
: 1 from sklearn import metrics
```

Calculando las métricas de error

```
: 1 # Mean Absolute Error  
2 metrics.mean_absolute_error(y_test,y_pred)
```

```
: 1.962837799904773
```

```
: 1 # Mean Squared Error  
2 metrics.mean_squared_error(y_test,y_pred)
```


```
: 6.423322381500185
```

```
: 1 # Root Medium Squared Error  
2 metrics.mean_squared_error(y_test,y_pred)**.5
```

```
: 2.53442742675741
```

Coeficiente de determinación (R-cuadrado)

Mide cuán bien ajusta nuestro modelo a los datos, es decir, mide la proporción de varianza de la variable objetivo que el modelo es capaz de explicar. Este coeficiente oscila entre 0 y 1, correspondiendo a 1 el ajuste perfecto del modelo y a 0 cuando la variable de salida no reacciona a nuestra variable predictora.

En los modelos , el score corresponde justamente al coeficiente de determinación.

```
1 # R-Squared
2 lm.score(X_test,y_test)
```

0.06336700925967509


En este ejemplo, el modelo sólo es capaz de explicar el 6,3% de la varianza de la variable de salida.

Visualizando los resultados

A continuación, graficaremos en un diagrama de dispersión las alturas de las madres e hijas, y la línea de regresión del modelo formulado.

```
plt.scatter(df_f['Mother'],df_f['Height'], label='Mediciones')
plt.plot(x,y, color='black', label='Regresion')
plt.xlabel('Altura Madre')
plt.ylabel('Altura Hija')
plt.title('Altura Madre v/s Hija')
plt.legend(loc=0)
```

<matplotlib.legend.Legend at 0x1b116bf9e08>




Análisis de residuales

Si analizamos la diferencia entre la predicción del modelo y el valor real, encontramos que dicho error se distribuye de forma normal.

```
sns.distplot(y_pred-y_true)
```

```
<matplotlib.axes._subplots.AxesSubplot at 0x1b116c52448>
```



Si la distribución del error no se asemeja a una distribución normal, entonces es recomendable revisar el modelo, pues podría no tener un comportamiento lineal-

Gracias